张建乐

AI 架构师 • 生产级 AI 系统

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

能建 AI 系统,也扛过资金级正确性:LLM 网关、长时记忆、Agent 平台、多模态均已上线;底座 10 年后端。

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由 / 工具编排 / 幻觉守门 → **2026.07** AI 基建层:LLM 网关 / 长时记忆 / 多租户 → **2026.10** 多模态产品层:生成质量可量化 / 合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位 / 成本 / 发布闸)、长时记忆(事件溯源 + RRF)、多租户配额 / 密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回 / 重排 / 评测)、三层幻觉守门
- **多模态应用**:图像编辑生成 + 分割 / 发丝级 matting 后处理、质量可量化评测(像素差 / 身份相似度 / 色差)、成本闸与合规标识
- **AI 工程化治理**:自治研发流水线、证据链质量判官、发布 SHA 门禁、Hook 体系
- **团队与协作**:0-1 组建金融技术团队、0-1 系统建设、跨端联调、核心攻坚与带教

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

多厂商网关(换厂商不改代码)+ 长时记忆(事件溯源 + 双臂召回)

- **问题**:网关端到端 30s —— 请求路径三处同步阻塞(CK 建连 + DDL 约 120ms)卡在异步事件循环,端到端测不出瓶颈;长时记忆单臂向量召回不足;换厂商要改代码
- **行动**:分段计时定位阻塞点 → 全异步化 + 连接池 + 用量写库转有界队列(2000)后台线程落库;事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF 融合 + 强命中保护;语义档位路由(轻 / 重模型)+ 多租户日配额与 key 隔离 + 双实例滚动替换(5xx 发布闸,失败回退旧 tag);评测先行 —— 重排上线前实测负贡献即关停
- **结果**:端到端 **30.1s → 3.6s**;P@1 **0.853 → 0.907**(n=75 同口径 A/B);重排 **R@4 0.797 → 0.707** 被实测否决(并量化评测工具自身 16.3% 翻面噪声);单会话成本 **-60%**;5 厂商 / 12 模型 / 9 客户端 · 51 天稳定

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

plan-execute 编排 + 权限闸 + 三层幻觉守门,内部与外部双入口

- **问题**:规则基线误路由偏高;内部 / 外部双入口,高风险操作需安全合规
- **行动**:plan-execute 执行链 + **4 条权限闸**(scope 隔离 / 认证 / 用户 / 高风险显式放行)+ 连续澄清 3 次自动转人工;两套系统提示词 **13 条**强制约束(业务 8 + 知识 5)+ 内 / 外 / 用户三级可见性 + 审计脱敏
- **结果**:**45 条离线评测集**覆盖澄清拦截 / 高风险转人工 / 多工具组合;54 项回归全绿;双入口已上线运行

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

不换脸管线 —— 只换发型,脸 / 身体 / 背景保持原照片像素

- **问题**:模型整图重画,脸会漂移(提示词级约束不可靠);长 → 短换发旧发残留;后处理 85s 拖慢出图
- **行动**:补边 3:4 → ARK 生成 → 裁回逐像素对位 → 蒙版取「原图旧发羽化区 ∪ 生成图新发 alpha」并集 → ViTMatte 发丝级 alpha → Image.composite 合成;分割 512→256、matting 512→384(逐区对照视觉无差)
- **结果**:脸区像素差降到 JPEG 噪声级(**P99 5~8**,对照仅提示词 33)、身份 cos **0.958~0.975**;后处理 **85s → 14.7s**,公网端到端 **48.0s**;并发闸 6 控成本 + AI 生成标识(显式角标 + EXIF/COM 隐式)

金融导流平台 + 渠道接入 AI 工作台 ｜ 重庆智识维度 · 技术负责人 2026.06-至今

上游流量 → 撞库 → 前筛 → 资方授信 / 放款 → 对账,已上生产;渠道接入九阶段自治流水线

- **平台 • 问题**:生产撞库雪崩(缺索引 + 超时重试正反馈),平均耗时 6.6s;渠道 / 资方差异持续扩散;跨库双写会丢、双实例日限额超发、账对不平
- **平台 • 行动**:索引 + 超时治理 + 三层弹性(有界扇出池满队列退化为调用线程、每渠道熔断 5 次失败 / 30s 半开只计远程异常、撞库池 SynchronousQueue 直扩 64 线程);13 类 Canonical 模型收口核心域 + 适配器 SPI + 注册表按渠道类型自动索引;四类 Outbox(事务内写 PENDING、失败逐行隔离重投、超 10 次 DEAD 死信)+ 日限额 Redis INCR 原子预占 + 实时流水 → 日终闭账 → 幂等净补差
- **平台 • 结果**:撞库平均 **6.6s → 264ms**(同窗口 A/B,峰值在途 72.9 → 3.24);下游进件 **29.5s → 2.5s**;接新渠道 = 一条配置 + 一个实现 bean,核心域零改动;账不平可定位到逐笔流水,改价当天回溯、历史留单价快照;发布逐台摘流 / 双身份校验 / trace_id 全链路入 ClickHouse
- **工作台 • 问题**:渠道接入 4 周级人工:文档人读、验签解密 / 报文转换 / 回调适配手写、联调人盯;AI 进生产缺可信闸
- **工作台 • 行动**:Tauri 2(Rust + React)九阶段流水线(文档解析 → 规格人工闸 → 代码生成 → 编译闭环 → 用例生成 / 执行 → 报文比对 → 上线六步链 → 知识沉淀);LLM 只出现在 3 处(文档抽取 / 编排片段 / 编译修复),比对判定与模板渲染 100% 程序化;审批挂起落库(杀进程重启可恢复);签名域 fail-closed;编译失败 LLM 整文件修复 ≤5 轮
- **工作台 • 结果**:全链真机跑通:46 文件落盘 / 上线 15/15 对 mock / 知识检索 1ms;KR3 定位 100% / 误报 0%;覆盖率实测 79.83% 定 ≥79% 回归闸;前端 545 + Rust 363 测试全绿

工作经历

重庆智识维度 ｜ 技术负责人 2026.06-至今

- 贷超导流双产品线全链路(撞库 → 前筛 → 路由 → 授信 / 放款 → 对账)

同司 AI 基建 ｜ 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 ｜ 独立开发 2025.12-2026.06

- 在读硕士期间:自研量化 / AI 员工 / 多模态 RAG / DeepResearch 系统

小象优品 ｜ Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产 / 资金端重构、锁治理

豌豆思维 ｜ Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 ｜ Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 ｜ Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)