张建乐

AI 架构师 • 生产级 AI 系统

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

能建 AI 系统,也扛过资金级正确性:多厂商 LLM 网关、长时记忆、Agent 平台、多模态应用均已上线;底座是 10 年后端架构与稳定性治理。

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由 / 工具编排 / 幻觉守门 → **2026.07** AI 基建层:LLM 网关 / 长时记忆 / 多租户 → **2026.10** 多模态产品层:生成质量可量化 / 合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象 / 成本计量 / 滚动发布闸)、长时记忆(事件溯源 + 双臂召回 RRF)、多租户配额与密钥隔离、 MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回 / 重排 / 评测)、三层幻觉守门
- **多模态应用**:图像编辑生成 + 分割 / 发丝级 matting 后处理、质量可量化评测(像素差 / 身份相似度 / 色差)、成本闸与合规标识
- **AI 工程化治理**:自治研发流水线、证据链质量判官、发布 SHA 门禁、Hook 体系
- **后端与平台架构**:防腐层 ACL / 适配器 SPI、状态机与终态保护、分布式一致性(锁 / Outbox / CAS)、高并发与海量数据
- **数据与可观测**:ClickHouse、Redis、Elasticsearch、MySQL 分库分表、JVM 调优、trace_id 全链路

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

多厂商网关(换厂商不改代码)+ 长时记忆(事件溯源 + 双臂召回)

- **网关性能**:请求路径三处同步阻塞(CK 建连 + DDL 约 120ms 卡在异步事件循环)→ 全异步化 + 连接池 + 用量写库转有界队列(2000)后台线程落库 → 端到端 **30.1s → 3.6s**;分段计时才定位到这 120ms,端到端测不出
- **长时记忆**:单臂向量召回不足 → 事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF 融合 + 强命中保护 → **P@1 0.853 → 0.907**(n=75 同口径 A/B);热 Redis 冷 CK 分层
- **评测先行(否决自己的优化)**:cross-encoder 重排凭直觉该涨分,实测 **R@4 0.797 → 0.707** 负贡献 → 关停;并量化评测工具自身噪声(重跑 **16.3% 翻面**)
- **平台化**:语义档位路由(轻 / 重模型,换厂商不改代码)+ 多租户日配额与 key 隔离 + 双实例滚动替换(5xx 发布闸,失败回退旧 tag)→ 单会话成本 **-60%**

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

plan-execute 编排 + 权限闸 + 三层幻觉守门,内部与外部双入口

- **意图路由与工具编排**:规则基线误路由偏高 → plan-execute 执行链 + 4 条权限闸 + 连续澄清 3 次自动转人工 → 意图识别 **70% → 90%**(45 条种子 case 离线回放,route 与 tool 双对才算对)
- **安全合规**:两套系统提示词共 **13 条**强制约束(业务 8 + 知识 5)+ 内 / 外 / 用户三级可见性 + 审计脱敏

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

不换脸管线 —— 只换发型,脸 / 身体 / 背景保持原照片像素

- **问题**:模型整图重画,脸会漂移(提示词级约束不可靠)→ 补边 → ARK 生成 → 裁回 → 蒙版并集 → ViTMatte 发丝级 alpha → Image.composite 合成 → 脸区像素差降到 JPEG 噪声级(**P99 5~8 vs 对照 33**)
- **发缘质量**:羽化蒙版会透出旧发晕影 → 蒙版取「原图旧发羽化区 ∪ 生成图新发 alpha」并集 + 发丝级 matting → 长→短换发无残留
- **性能与上线**:后处理 85s → **14.7s**(分割 512→256 提速 8.7×、matting 512→384 提速 3.2×);公网端到端 **48.0s**;并发闸 6 控成本 + AI 生成标识(显式角标 + EXIF/COM 隐式)

金融导流平台(双产品线) | 重庆智识维度 · 技术负责人 2026.06-至今

上游流量 → 撞库 → 前筛 → 路由资方 → 授信 / 放款 → 双向对账,已上生产

- **稳定性与弹性**:生产撞库雪崩(缺索引 + 超时重试正反馈)→ 索引 + 超时治理 + 三层弹性(有界扇出池满队列退化为调用线程、每渠道熔断 5 次失败 / 30s 半开且只计远程异常、撞库池 SynchronousQueue 直扩 64 线程)→ **平均耗时 6.6s → 264ms**(同窗口 A/B,峰值在途 72.9 → 3.24);下游进件 GC 冻结 → 参数与 GC 调优 + 终态保护 → **29.5s → 2.5s**
- **N×M 集成枢纽(防腐层 ACL)**:渠道 / 资方差异持续扩散 → 13 类 Canonical 模型收口核心域 + 适配器 SPI(可选能力用 default 方法)+ 注册表按渠道类型自动索引 → 接一家新渠道 = 一条 apiConfig + 一个实现 bean,核心域零改动
- **资金正确性**:跨库双写会丢、双实例下日限额超发 → 四类 Outbox(事务内写 PENDING、整批失败逐行隔离重投防毒数据拖垮全批、超 10 次标 DEAD 死信)+ 日限额 Redis INCR 原子预占(替掉单机 synchronized)+ 实时逐笔流水 → 日终闭账 → 幂等净补差(改价当天回溯,历史留单价快照)
- **发布与可观测**:逐台摘流 / 双身份校验 / 全量回滚点;trace_id 全链路入 ClickHouse,ERROR 巡检 + 熔断翻转落事件
- 技术栈:Spring Boot、MyBatis-Plus、MySQL 8、Redis、ClickHouse、XXL-JOB、Docker / K8s

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路(撞库 → 前筛 → 路由 → 授信 / 放款 → 对账)

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

小象优品 | Java 资深开发 2021.12-2025.11

- 消费金融核心链路(2024.06 起兼 Agent 平台核心开发):资产端与资金端重构、多家资产方与资金方接入、扣款时序与分布式锁治理;团队收缩后留守核心

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)