张建乐

AI 架构师 • 生产级 AI 系统

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

近 3 年把 LLM 网关、长时记忆、Agent 平台、多模态应用落成上线系统;此前 10 年做后端架构与稳定性治理。

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识
- **AI 工程化治理**:自治研发流水线、证据链质量判官、发布 SHA 门禁、Hook 体系
- **团队与协作**:0-1 组建金融技术团队、0-1 系统建设、跨端联调、核心攻坚与带教

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

多厂商 LLM 网关与长时记忆(事件溯源、双臂召回)

- 网关端到端 30.1s、瓶颈无法定位:分段计时定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞卡在异步事件循环;经全异步化、连接池与用量有界队列改造,降至 **3.6s**
- 多厂商 API 各自为政,换家需改代码、单点故障断链:抽象语义档位路由 + 链式换家 + 5xx 发布闸;换厂商零代码改动,单会话成本 **-60%**,5 厂商 12 模型 9 客户端稳定运行 51 天
- 长时记忆向量单臂召回 P@1 0.853:改事件溯源(纯追加 SSOT + 投影)+ 词法/向量双臂 RRF 融合,提升至 **0.907**;cross-encoder 重排经同口径 A/B 实测为负贡献,未上线

金融导流平台 + 渠道接入 AI 工作台 | 重庆智识维度 · 技术负责人 2026.06-至今

贷超导流全链路已上生产(撞库、前筛、资方授信、放款、对账);渠道接入由 4 周人工升级为九阶段流水线

- 生产撞库雪崩(缺索引叠加超时重试正反馈)平均 6.6s:索引与超时治理 + 三层弹性(有界池、每渠道熔断半开、撞库池直扩 64 线程),平均降至 **264ms**,峰值在途 72.9 → 3.24
- 渠道与资方差异手工适配、改一处崩一片:核心域只认 **13 类** Canonical 模型,差异收敛至适配器 SPI 与注册表,新渠道接入 = 一条配置 + 一个实现类,下游进件超时 **29.5s → 2.5s**
- 跨库双写丢失、双实例日限额超发、账单不平:四类 Outbox(事务内 PENDING、逐行重投、超 10 次死信)+ Redis INCR 原子占额 + 日终闭账净补差,账不平可定位至逐笔
- 渠道接入原为 4 周级人工(文档人工阅读、验签与报文转换手写、联调人工值守):建成九阶段流水线(文档、规格闸、代码生成、编译、用例、报文比对、上线、知识沉淀),LLM 仅在抽取、编排、编译修复三处介入
- 规格与产物经人工闸收口,审批挂起落库(进程重启可恢复),签名域 fail-closed;全链真机验证:**46 文件**落盘、上线 15/15 对 mock、知识检索 1ms,**545 + 363** 测试全绿

自治 AI 员工系统(排班值班 + 评审门) | 自主创业 · 独立开发 2026.04-至今

AI 员工自治值班体系:排班调度、安全闸、双模型评审门

- AI 自主执行存在失控风险(幻觉误改、越权删除、交付不可追溯):排班调度(4 条每日循环)+ 自治值班(每 30 分钟一班)+ 安全闸 Hook(拦截删库、强推);累计自治值班 **489** 班次,过程事件全量入记忆湖,4500+ 条可溯源
- 涉钱改动经双 LLM 异构评审门(OpenAI 与 Gemini 双 PASS 放行),2026-06-14 上线后持续执行

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

只换发型不换脸:脸、身体、背景保持原照片像素

- 模型整图重画致人脸漂移,提示词约束不可靠,长发改短发残留旧发:补边 3:4 生成后逐像素裁回,蒙版取原图旧发与新发 alpha 并集,ViTMatte 发丝级合成,人脸保持原图像素
- 效果按像素级核对:脸区像素差 P99 **5~8**(对照组 33),身份 cos **0.958~0.975**
- 后处理耗时 85s 制约出图:分割 512→256、matting 512→384(逐区对照无差),后处理降至 **14.7s**,公网端到端 **48s**;并发闸 6 控成本,AI 生成标识(显式角标 + EXIF/COM 隐式)已合规上线

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

内外双入口的金融问答 Agent:plan-execute 编排、权限闸、幻觉守门

- 规则基线误路由率偏高,且需区分内部、外部双入口:构建 plan-execute 执行链 + **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行),澄清 3 次自动转人工
- 幻觉与越权话术由 **13 条**系统提示词约束(业务 8、知识 5),配套内部、外部、用户三级可见性与审计脱敏,随双入口上线运行
- 以 **45 条**离线评测集验收(澄清拦截、高风险转人工、多工具组合),54 项回归全绿

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)