张建乐

AI 架构师 • 生产级 AI 系统

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

近 3 年把 LLM 网关、长时记忆、Agent 平台、多模态应用落成上线系统;此前 10 年做后端架构与稳定性治理。

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识
- **AI 工程化治理**:自治研发流水线、证据链质量判官、发布 SHA 门禁、Hook 体系
- **团队与协作**:0-1 组建金融技术团队、0-1 系统建设、跨端联调、核心攻坚与带教

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

项目描述:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

技术栈:Python asyncio、SSE 流式转发、ClickHouse、Redis、Prometheus 观测

- 端到端 30.1s、瓶颈无法定位:分段计时定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞卡在异步事件循环;全异步化 + 连接池 + 用量写库转有界队列后台落库,降至 **3.6s**
- 多厂商 API 各自为政、换家需改代码:抽象语义档位路由(轻 / 重模型)+ 链式换家(防同账号互切)+ 线程本地连接与代次失效重建,换厂商零代码改动
- 单点故障断链:5xx 发布闸 + 滚动替换,一家挂了自动切走;单会话成本 **-60%**,5 厂商 12 模型 9 客户端稳定运行 51 天
- 长时记忆向量单臂召回 P@1 0.853:事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF 融合,提升至 **0.907**
- cross-encoder 重排经同口径 A/B 实测为负贡献(R@4 0.797 → 0.707),未上线;量化出评测工具自身 16.3% 翻面噪声,据此设定评测可信度门槛

技术难点:1. 异步事件循环被同步 IO 阻塞:分段计时逐段排除,不凭经验调参 2. 换家防同账号互切:链式换家 + 代次失效重建,避免复用已失效凭证 3. 评测尺子自身噪声:同口径 A/B + 翻面率量化,不用不可信评测做技术决策

金融导流平台 + 渠道接入 AI 工作台 | 重庆智识维度 · 技术负责人 2026.06-至今

项目描述:贷超导流生产系统,链路:上游流量 → 撞库去重 → 前筛路由 → 下游资方授信 / 放款 → 对账;含渠道接入九阶段 AI 流水线

技术栈:Java 11、Spring Boot、MySQL 分库、Redis、ClickHouse、XXL-JOB、适配器 SPI

- 生产撞库雪崩(缺索引叠加超时重试正反馈)平均 6.6s:索引与超时治理 + 三层弹性(有界池背压、每渠道熔断半开、撞库池直扩 64 线程),平均降至 **264ms**,峰值在途 72.9 → 3.24

- 渠道与资方差异手工适配、改一处崩一片:核心域只认 **13 类** Canonical 模型,差异收敛至适配器 SPI 与注册表,新渠道接入 = 一条配置 + 一个实现类,核心域零改动
- 下游进件超时 29.5s:重排适配器超时与重试策略、连接复用,降至 **2.5s**(ZQX test 同路径实测)
- 跨库双写丢失:四类 Outbox(事务内 PENDING、行级隔离重投、超 10 次死信);双实例日限额超发:Redis INCR 原子占额;账单不平:日终闭账净补差,可定位至逐笔
- 渠道接入原为 4 周级人工(文档人工阅读、验签与报文转换手写、联调人工值守):建成九阶段流水线(文档、规格闸、代码生成、编译、用例、报文比对、上线、知识沉淀),LLM 仅在抽取、编排、编译修复三处介入,判定 100% 程序化
- 规格与产物经人工闸收口,审批挂起落库(进程重启可恢复),签名域 fail-closed;全链真机验证:**46 文件**落盘、上线 15/15 对 mock、知识检索 1ms、覆盖率实测 79.83%(闸 ≥79%),**545 + 363** 测试全绿

技术难点:1. 撞库雪崩的恶性循环:超时重试正反馈,治超时比加机器有效 2. 跨库一致性:Outbox 至少一次 + 幂等净补差,宁重不丢 3. AI 生成代码进生产:人工闸 + 挂起落库 + fail-closed,中断可恢复

自治 AI 员工系统(排班值班 + 评审门) ｜ 自主创业 · 独立开发 2026.04-至今

项目描述:自治 AI 员工系统:AI 7×24 自主值班研发,含排班调度、安全闸、双模型评审门与全量事件溯源

技术栈:Python 调度、LLM(OpenAI + Gemini 异构评审)、ClickHouse 事件表、Hook 体系

- AI 自主执行存在失控风险(幻觉误改、越权删除、交付不可追溯):排班调度(4 条每日循环)+ 自治值班(每 30 分钟一班)+ 安全闸 Hook(拦截删库、强推)
- 累计自治值班 **489** 班次,过程事件全量入记忆湖(事件溯源表),4500+ 条可溯源
- 涉钱改动经双 LLM 异构评审门(OpenAI 与 Gemini 双 PASS 放行),2026-06-14 上线后持续执行

技术难点:1. 不可控:安全闸拦危险操作 + 事件溯源可追责 2. 谁来把关涉钱改动:双模型异构评审,单模型放行不算数

假发 AI 试戴(在线作品) ｜ 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

项目描述:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

技术栈:Python、ARK 图像生成、ONNX 分割与 ViTMatte、FastAPI、Nginx + LE 证书

- 模型整图重画致人脸漂移、提示词约束不可靠:补边 3:4 生成后逐像素裁回,蒙版取原图旧发与新发 alpha 并集,ViTMatte 发丝级合成
- 长发改短发残留旧发:蒙版并集 + matting 逐像素判边,发缘干净无残留
- 效果按像素级核对:脸区像素差 P99 **5~8**(对照组 33),身份 cos **0.958~0.975**(对照组 0.918)
- 后处理耗时 85s 制约出图:分割 512→256、matting 512→384(逐区对照无差),后处理降至 **14.7s**,公网端到端 **48s**
- 并发闸 6 控制成本;按合规要求输出 AI 生成标识(显式角标 + EXIF/COM 隐式),已上线

技术难点:1. 生成模型不可控:绕开「让模型画脸」,改像素级合成,脸保持原图 2. 发丝边缘:分割定核心、matting 判边缘带,失败退回羽化 mask 不中断服务

金融智能问答 Agent 平台 ｜ 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

项目描述:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

技术栈:Python、plan-execute 编排、LLM 工具调用、三级可见性、pytest 回归

- 规则基线误路由率偏高、需区分内外双入口:构建 plan-execute 执行链 + **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行)
- 高风险操作走显式放行闸,澄清 3 次自动转人工,把不确定性挡在人工兜底前
- 幻觉与越权话术由 **13 条**系统提示词约束(业务 8、知识 5),配套内部、外部、用户三级可见性与审计脱敏,随双入口上线运行
- 工具调用回归以 **45 条**离线评测集覆盖(澄清拦截、高风险转人工、多工具组合三类场景),54 项自动化回归全绿

技术难点:1. 误路由与越权:权限闸 + 澄清阈值双保险 2. 三级可见性:同一知识库对内部 / 外部 / 用户呈现不同内容,脱敏在出口统一处理

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)