张建乐

AI 架构师 • 生产级 AI 系统

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

近 3 年把 LLM 网关、长时记忆、Agent 平台、多模态应用落成上线系统;底座是 10 年后端架构与稳定性治理。

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识
- **AI 工程化治理**:自治研发流水线、证据链质量判官、发布 SHA 门禁、Hook 体系
- **团队与协作**:0-1 组建金融技术团队、0-1 系统建设、跨端联调、核心攻坚与带教

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

项目描述:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

主要挑战:1. 端到端 30.1s、瓶颈无法定位:请求路径上 CK 建连、DDL 元数据查询(约 120ms)等多处同步 IO 阻塞在异步事件循环里,分段计时前无法区分是网络、写库还是第三方 API 慢 2. 多厂商 API 各自为政:各家协议、错误码、限流策略不同,换厂商要改代码;一家故障断整条链路,简单切备用账号还会踩同账号互切的坑 3. 长时记忆召回不足:向量单臂召回 P@1 仅 0.853,长尾问题命中差;重排收益与评测集可信度均缺量化依据

核心优化与实现:

- **性能治理**
- 分段计时定位:请求路径埋点逐段计时,定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞
- 全异步化 + 连接池:同步 IO 全改异步、连接复用;用量写库转有界队列后台落库,不阻塞请求路径,端到端降至 **3.6s**
- **多厂商接入与容灾**
- 档位路由:抽象轻 / 重语义档位,按请求复杂度自动选模型,单会话成本 **-60%**
- 链式换家:故障时链式切换备用厂商(防同账号互切),线程本地连接 + 代次失效重建,换厂商零代码改动
- 发布闸:滚动替换 + 5xx 比例闸,异常版本在发布过程自动拦截
- **长时记忆**
- 事件溯源:纯追加 SSOT + 投影,任何时点可重建记忆状态
- 双臂召回:词法 + 向量 RRF 融合,P@1 0.853 → **0.907**
- 重排实测:cross-encoder 同口径 A/B 为负贡献(R@4 0.797 → 0.707),已关停
- 评测治理:量化出评测工具自身 16.3% 翻面噪声,设定评测可信度门槛

项目成果:1. 性能与成本:端到端 30.1s → 3.6s,单会话成本 -60%;支撑 9 个客户端、5 厂商 12 模型稳定运行 51 天 2. 记忆质量:P@1 0.853 → 0.907;重排负贡献经同口径 A/B 否决并关停 3. 评测可信:评测工具 16.3% 翻面噪声被量化并设为门槛,技术决策有可信评测依据

技术栈:

- 服务:Python asyncio、SSE 流式转发、有界队列
- 存储与观测:ClickHouse、Redis、Prometheus
- 容灾:链式换家、代次失效重建、滚动替换 + 5xx 发布闸

金融导流平台 + 渠道接入 AI 工作台 | 重庆智识维度 · 技术负责人 2026.06-至今

项目描述:贷超导流生产系统,链路:上游流量 → 撞库去重 → 前筛路由 → 下游资方授信 / 放款 → 对账;含渠道接入九阶段 AI 流水线

主要挑战:1. 生产撞库雪崩:缺索引叠加超时重试正反馈,越慢越重试,平均 6.6s 2. 渠道与资方差异持续扩散:N×M 手工适配,改一处崩一片 3. 跨库双写会丢、双实例日限额超发、账单对不平 4. 渠道接入 4 周级人工:文档人工阅读、适配手写、联调人工值守;AI 生成代码进生产缺可信闸

核心优化与实现:

- 生产撞库雪崩(缺索引叠加超时重试正反馈)平均 6.6s:索引与超时治理 + 三层弹性(有界池背压、每渠道熔断半开、撞库池直扩 64 线程),平均降至 **264ms**,峰值在途 72.9 → 3.24
- 渠道与资方差异手工适配、改一处崩一片:核心域只认 **13 类** Canonical 模型,差异收敛至适配器 SPI 与注册表,新渠道接入 = 一条配置 + 一个实现类,核心域零改动
- 下游进件超时 29.5s:重排适配器超时与重试策略、连接复用,降至 **2.5s**(ZQX test 同路径实测)
- 跨库双写丢失:四类 Outbox(事务内 PENDING、行级隔离重投、超 10 次死信);双实例日限额超发:Redis INCR 原子占额;账单不平:日终闭账净补差,可定位至逐笔
- 渠道接入原为 4 周级人工(文档人工阅读、验签与报文转换手写、联调人工值守):建成九阶段流水线(文档、规格闸、代码生成、编译、用例、报文比对、上线、知识沉淀),LLM 仅在抽取、编排、编译修复三处介入,判定 100% 程序化
- 规格与产物经人工闸审批,审批挂起落库(进程重启可恢复),签名域 fail-closed;全链真机验证:**46 文件**落盘、上线 15/15 对 mock、知识检索 1ms、覆盖率实测 79.83%(闸 ≥79%),**545 + 363** 测试全部通过

项目成果:1. 撞库 **6.6s** → **264ms**;下游进件超时 **29.5s** → **2.5s** 2. 新渠道接入 = 一条配置 + 一个实现类,核心域零改动 3. 全链真机:46 文件落盘、上线 15/15 对 mock、覆盖率 79.83%、**545 + 363** 测试全部通过

技术栈:Java 11、Spring Boot、MySQL 分库、Redis、ClickHouse、XXL-JOB、适配器 SPI

自治 AI 员工系统(排班值班 + 评审门) | 自主创业 · 独立开发 2026.04-至今

项目描述:自治 AI 员工系统:AI 7×24 自主值班研发,含排班调度、安全闸、双模型评审门与全量事件溯源

主要挑战:1. 不可控:AI 自主执行会幻觉误改、越权删除,出事代价大 2. 不可追溯:交付过程无记录,问题无法定位到步骤与操作者 3. 涉钱改动:AI 生成代码合入资金相关逻辑,缺把关机制

核心优化与实现:

- **调度与安全**
- 排班调度:4 条每日循环(资讯 / 巡检 / 复盘 / 内容),覆盖日常研发
- 自治值班:每 30 分钟一班自主值班,发现问题自主处理
- 安全闸 Hook:拦截删库、强推等危险操作,执行前强制校验
- **溯源与门禁**
- 事件溯源:过程事件全量入记忆湖(事件溯源表),任何动作可回溯
- 双 LLM 异构评审门:OpenAI 与 Gemini 双 PASS 才放行

项目成果:1. 自主值班 **489** 班次,记忆湖 4500+ 条可溯源 2. 2026-06-14 起涉钱改动双模型评审通过才合入

技术栈:

- 调度:Python 调度器、4 条每日循环 + 30 分钟值班
- 治理:安全闸 Hook、双 LLM 异构评审门(OpenAI + Gemini)
- 溯源:ClickHouse 事件表

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

项目描述:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

主要挑战:1. 人脸漂移:模型整图重画,脸必漂移;提示词约束不可靠,换发后脸不一致,效果不可信 2. 旧发残留:长发改短发时,生成图里的旧发在边缘残留晕影 3. 速度与成本:后处理 85s 拖慢出图体验;公网并发下 API 成本不可控 4. 合规:AI 生成内容需按监管要求标识,人脸素材涉及单独同意

核心优化与实现:

- **不换脸管线**
- 像素级对齐:补边 3:4 生成后逐像素裁回,与原图严格对位
- 蒙版合成:蒙版取原图旧发 ∪ 新发 alpha 并集,ViTMatte 发丝级 matting,脸、身体、背景保持原照片像素
- 质检量化:脸区像素差 P99 **5~8**(仅提示词对照 33)、身份 cos **0.958~0.975**(对照 0.918),量化支撑换发不换脸
- **性能与成本**
- 分辨率降档:分割 512→256、matting 512→384,3x 放大逐区对照确认视觉无差,后处理 85s → **14.7s**
- 并发闸:同时最多 6 个任务,API 成本可控
- **合规**
- AI 生成标识:显式角标 + EXIF/COM 隐式双写;人脸素材单独同意弹层

项目成果:1. 脸区像素差 P99 5~8(对照 33):脸即原照片像素,换发不换脸 2. 后处理 85s → 14.7s,公网端到端 48s 3. 已上线运营(独立域名 + LE 证书),合规标识随图输出

技术栈:

- 生成:ARK 图像生成、补边对齐、蒙版合成
- 后处理:ONNX 分割、ViTMatte 发丝级 matting
- 服务:FastAPI、并发闸 6、Nginx + LE 证书

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

项目描述:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

主要挑战:1. 规则基线误路由率偏高:问题意图靠规则匹配,错误路由导致答非所问与工具误调,影响坐席效率 2. 高风险操作无闸:AI 直连业务工具存在越权风险,改单、退费类操作需要人工确认 3. 幻觉与越权话术:同一知识库对内 / 对外口径不同,直接暴露给用户有合规风险 4. 效果验证无标准:工具调用链路的正确性缺评法,改一次提示词不知道是好是坏

核心优化与实现:

- **编排与权限**
- plan-execute 执行链:先规划再执行,复杂问题拆解后逐步执行,收敛误路由
- **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行):高风险操作必须人工放行
- 澄清兜底:意图不明确时最多澄清 3 次,超过自动转人工
- **幻觉与合规守门**
- **13 条**系统提示词约束(业务 8、知识 5):约束回答范围与话术,防幻觉与越权承诺
- 三级可见性:内部、外部、用户三级内容隔离,审计脱敏在出口统一处理
- **效果验证**
- **45 条**离线评测集:覆盖澄清拦截、高风险转人工、多工具组合三类场景

- 54 项自动化回归:提示词与编排改动必须过回归,防止改一处坏一处

项目成果:1. 双入口上线运行,高风险操作全走显式放行闸 2. 45 条评测集 + 54 项回归全部通过,提示词迭代有依据

技术栈:

- 应用:Python、plan-execute 编排、LLM 工具调用
- 治理:4 条权限闸、13 条提示词约束、三级可见性
- 验证:45 条评测集、pytest 54 项回归

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)