张建乐

大模型应用开发工程师 · 金融场景

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

意图识别 **70%→90%** · 单会话成本 **-60%** · 评测集 **1,200+ 条** · 记忆召回 **P@1 0.907** ｜ RAG 全链路 · Agent 工具编排 · 评测闭环 ｜ **10 年**工程 · **6 年**金融

把大模型接进真业务:金融合规场景的 RAG 全链路、Agent 工具编排与评测驱动迭代(意图识别 70%→90%、单会话成本 -60%);企业级平台自研而非采购;微调/对齐有完整数据工程与训练管线实践。10 年金融后端底座,懂业务正确性,幻觉守门宁拒不编。

核心能力

- **RAG 全链路**:多模态解析(MinerU/dots-OCR)、两级切分、FTS+向量混合召回、cross-encoder 重排、RAGAS 在线自评、幻觉守门(召回不足强制兜底)
- **Agent 与工具编排**:Tool Calling/Planner/ToolRegistry、policy 工具权限闸、置信度路由、连续澄清转人工、SSE 流式、LangGraph 状态图工作流
- **评测与对齐**:人工标注评测集+offline replay+diff/root-cause/版本化;LoRA/DPO 数据工程(3,000+ 意图指令、1,500+ 偏好对)、MacBERT/BGE 对照实验、OpenVINO int8 量化部署(7.5x)
- **工程实现**:Python(asyncio/FastAPI)、Milvus/SQLite FTS/Redis VECTOR/ClickHouse、RPM 限速与 429 退避、Prompt 工程
- **金融与后端**:贷前贷中贷后、资产/资金端、合规审计(权限隔离/脱敏/越权拦截);Java/Spring、MySQL/Redis/ES

项目经历

金融智能问答与 Agent 平台 ｜ 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

金融合规场景企业级智能查询与工具编排平台:外/内双场景,3 业务应用+1 共享中台;通用知识库无法满足权限差异与审计合规 → 全程自研。

- **意图路由与可控性**:规则基线(14 类)误路由偏高 → 三级置信度阈值+policy-aware 执行(4 条工具权限闸)+分类器可插拔 → 意图识别 **70%→90%**(1,200+ 样本离线回放口径);连续澄清 3 次自动转人工
- **工具编排与知识链路**:额度/借款/还款/物流 4 大业务域 → ToolRegistry/Executor/Planner 联动、900+ 篇文档接入(MinerU 版面解析)+双路召回+cross-encoder 重排 → 全程可解释可审计;幻觉守门(召回不足宁拒不编)
- **评测闭环**:迭代无标尺 → 1,200+ 条人工标注评测集(五类,含 600+ 工具调用样本)+offline replay+diff/root-cause/四维版本化 → 分层调度(轻/重模型)后单会话 token 成本 **-60%**
- **安全合规**:内/外/用户三级可见性权限+scope 越权拦截+身份字段服务端覆写+12 字段审计(落盘前递归脱敏)+13 条 prompt 防编造硬约束
- 技术栈:Python、FastAPI、SQLite FTS、Sentence-Transformers、Milvus、Reranker、LangGraph、RAGAS

企业级 LLM 网关与长时记忆 ｜ 同司 AI 基建 · 主导 2026.07-至今

- **LLM 网关**(Python asyncio):多供应商统一接入、语义档位路由(换厂商不改代码)、流式透传、token 用量与成本计量;请求路径三处同步阻塞治理 → 端到端 **30.1s→3.6s**,蓝绿零断流
- **长时记忆系统**:单臂向量召回不足 → 事件溯源+词法/向量双臂 RRF 召回+强命中保护 → **P@1 0.45→0.907**;热 Redis 冷 CK 分层、每日零-token 自检回路
- MCP 封装记忆中间件,多项目共享同一记忆底座,支撑多 Agent 协作

金融导流平台(双产品线) ｜ 重庆智识维度 · 技术负责人 2026.06-至今

AI-Native 交付模式:以 AI 为主力完成设计/开发/测试/运维;撞库→前筛→路由→授信/放款→对账全链路 0→1。

- **稳定性攻坚**:生产撞库雪崩(缺索引+超时重试正反馈)→ **6.6s→264ms(25x)**;下游进件超时(GC 冻结 26s)→ **29.5s→2.5s**;互斥锁防双推资损、Transactional Outbox、终态 CAS 出口
- 全量报文/日志/事件入 ClickHouse(trace_id 全链路),ERROR 巡检+飞书告警;发布门禁(逐台摘流/双身份校验/全量回滚点)
- 技术栈:Spring Boot、MyBatis-Plus、MySQL 8、Redis、ClickHouse、XXL-JOB、Docker/K8s

A 股量化研究系统 ｜ 独立自建(Qlib 重构) 2025.12-2026.06

数据底座 404 张表/67 采集管道/273 调度任务;策略指标虚高 → 三硬闸(DSR/PBO/ΔIC)拦截 Sharpe 虚高 2.2x 的模型上线;LLM 因子发现自动化;多 Agent 辩论交易与仲裁。

消费金融核心链路 ｜ 小象优品 · Java 资深开发 2021.12-2025.11

京东/360/百融等 5+ 资产方与多家资金方接入;资金最终一致治理(扣款时序/分布式锁/MQ 顺序消费);团队收缩后留守核心。

早期 ｜ 上海广升 / 上海致宇 · Java 开发 2016.07-2018.07

消息推送平台(日活千万级)、银行资管系统。

个人作品集(工程级,可现场演示)

- **多模态 RAG 工程**:扫描件/图表无法被纯文本检索 → dots-OCR(vLLM 部署)版面解析+标题/语义两级切分+多模态向量 → Milvus BM25/dense 混合检索 → LangGraph 10 节点工作流;RAGAS 在线自评(低分丢弃、<0.7 触发人工审批)
- **DeepResearch 编排引擎**:研究任务需人工多轮检索归纳 → 任务分解+主循环 ≤5 迭代 × ≤6 并行 OODA worker,质量门槛+收益递减早停 → FastAPI+SSE 流式输出;已服务化进生产链路(政策事实回指硬闸防 LLM 编造)

教育

- 史蒂文斯理工学院 计算机科学 硕士(在读,AI 方向,2025.09-2027.06);徐州工程学院 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)
- 模型工程实践:微调数据工程(3,000+ 意图指令、1,500+ DPO 偏好对、9 维 reward 计分)、LoRA/DPO 训练管线、MacBERT/BGE 中文金融意图识别对照(2,000 条)、OpenVINO int8 量化部署(7.5x 加速)