张建乐

大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

LLM 应用从原型做到上线:RAG、多模态生成、Agent 编排、小模型微调;有公网在线的多模态产品

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

项目描述:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

技术栈:Python asyncio、SSE 流式转发、ClickHouse、Redis、Prometheus 观测

- 端到端 30.1s、瓶颈无法定位:分段计时定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞卡在异步事件循环;全异步化 + 连接池 + 用量写库转有界队列后台落库,降至 **3.6s**
- 多厂商 API 各自为政、换家需改代码:抽象语义档位路由(轻 / 重模型)+ 链式换家(防同账号互切)+ 线程本地连接与代次失效重建,换厂商零代码改动
- 单点故障断链:5xx 发布闸 + 滚动替换,一家挂了自动切走;单会话成本 **-60%**,5 厂商 12 模型 9 客户端稳定运行 51 天
- 长时记忆向量单臂召回 P@1 0.853:事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF 融合,提升至 **0.907**
- cross-encoder 重排经同口径 A/B 实测为负贡献(R@4 0.797 → 0.707),未上线;量化出评测工具自身 16.3% 翻面噪声,据此设定评测可信度门槛

技术难点:1. 异步事件循环被同步 IO 阻塞:分段计时逐段排除,不凭经验调参 2. 换家防同账号互切:链式换家 + 代次失效重建,避免复用已失效凭证 3. 评测尺子自身噪声:同口径 A/B + 翻面率量化,不用不可信评测做技术决策

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

项目描述:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

技术栈:Python、ARK 图像生成、ONNX 分割与 ViTMatte、FastAPI、Nginx + LE 证书

- 模型整图重画致人脸漂移、提示词约束不可靠:补边 3:4 生成后逐像素裁回,蒙版取原图旧发与新发 alpha 并集,ViTMatte 发丝级合成
- 长发改短发残留旧发:蒙版并集 + matting 逐像素判边,发缘干净无残留
- 效果按像素级核对:脸区像素差 P99 **5~8**(对照组 33),身份 cos **0.958~0.975**(对照组 0.918)
- 后处理耗时 85s 制约出图:分割 512→256、matting 512→384(逐区对照无差),后处理降至 **14.7s**,公网端到端 **48s**

- 并发闸 6 控制成本;按合规要求输出 AI 生成标识(显式角标 + EXIF/COM 隐式),已上线

技术难点:1. 生成模型不可控:绕开「让模型画脸」,改像素级合成,脸保持原图 2. 发丝边缘:分割定核心、matting 判边缘带,失败退回羽化 mask 不中断服务

Agent 工具调用微调与能力边界评测 | 独立作品 · 独立完成 2026

项目描述:Agent 工具调用微调实践:验证 Qwen3-0.6B 能否承接工具调用,并以三维度分离评测给出能力边界

技术栈:Qwen3-0.6B、LoRA、DeepSpeed ZeRO-2、Transformers、Accelerate

- 验证小模型能否承接 Agent 工具调用:教师模型多轮 ReAct 合成 1140 条轨迹(6 条规则校验),Qwen3-0.6B 做 LoRA(r=16、α=32、lr 2e-5)
- 另设 2207 条全参对照,DeepSpeed ZeRO-2 双卡训练,merge_and_unload 合回基座(推理零开销)
- 评测按格式、工具选择、答案三维度分别计分:格式 **4/20 → 20/20** 全学会,工具选择 **0/10 → 2/10**、答案 **0/10 → 2/10** 学不动
- 结论:0.6B 可学会输出格式、无法学会工具选择,承接工具调用需 7B+ 或规则兜底

技术难点:1. 单卡显存不足:ZeRO-2 切优化器状态与梯度,双卡跑通 2. 「学没学会」混成一个分:三维度分离评测,避免总分掩盖边界

多模态 RAG 工程(图片语境化 + 在线自评) | 独立作品 · 独立完成 2025.12-2026.06

项目描述:多模态 RAG 工程(个人作品):PDF 图文统一检索 + LangGraph 工作流 + RAGAS 在线自评

技术栈:dots-OCR、qwen3-vl、Milvus(dense + 服务端 BM25)、LangGraph、RAGAS

- PDF 图片检索缺失(图与文本不在同一语义空间):dots-OCR 版面解析(bbox、11 类元素)+ 两级切分,qwen3-vl 生成图片语境化描述后向量化
- 图文共用稠密空间:Milvus 单集合 dense + 服务端 BM25 双路融合,纯文本查询可召回图片,省去自建 BM25 索引与一致性维护
- RAG 答错缺少拦截:将 RAGAS 自评接入 LangGraph 10 节点流程,检索侧不达标丢弃上下文,生成侧低于 0.7 触发人工审批,拒绝则联网兜底
- 低分时更换信息源而非重新生成(方向错误时重生成仅消耗 token);Embedding 侧 RPM 限速 + 429 退避保障外部配额
- 核心自研约 **2.8k** 行

技术难点:1. 图与文本的语义鸿沟:图片先语境化再向量化,共用稠密空间 2. 答案质量无守门:自评入流程,低分换源不重生成

DeepResearch 深度研究编排引擎 | 独立作品 · 独立完成 2025.12-2026.06

项目描述:DeepResearch 深度研究编排引擎(个人作品):多 worker 并行 OODA 编排 + 终止控制 + 结构化输出降级

技术栈:Python、FastAPI、SSE、并行 worker、结构化输出

- 深度研究易无限迭代、成本不可估:任务分解后并行执行 OODA worker(上限 6、典型 3,查询预算按复杂度 3/5/8)
- 终止设三保险(迭代上下限、质量门 80、收益递减),最坏成本按迭代 × worker × 预算封顶
- LLM 结构化输出存在失败率:输出两级降级,失败时返回低置信度骨架并将失败写入 limitations
- 服务化提供 FastAPI 202 + SSE 增量输出,拒删运行中任务;工程规模 9 模块 4.1k 行

技术难点:1. 无限迭代:三保险终止,成本可估 2. 单点失败拖垮整轮:降级骨架 + limitations 透出,失败可见

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

项目描述:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

技术栈:Python、plan-execute 编排、LLM 工具调用、三级可见性、pytest 回归

- 规则基线误路由率偏高、需区分内外双入口:构建 plan-execute 执行链 + **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行)

- 高风险操作走显式放行闸,澄清 3 次自动转人工,把不确定性挡在人工兜底前
- 幻觉与越权话术由 **13 条**系统提示词约束(业务 8、知识 5),配套内部、外部、用户三级可见性与审计脱敏,随双入口上线运行
- 工具调用回归以 **45 条**离线评测集覆盖(澄清拦截、高风险转人工、多工具组合三类场景),54 项自动化回归全绿

技术难点:1. 误路由与越权:权限闸 + 澄清阈值双保险 2. 三级可见性:同一知识库对内部 / 外部 / 用户呈现不同内容,脱敏在出口统一处理

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)