# 张建乐

## 大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

**10 年** 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

LLM 应用从原型做到上线:RAG、多模态生成、Agent 编排、小模型微调;有公网在线的多模态产品

## AI 轨迹(近 3 年)

**2024.06** Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

## 核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识

## 项目经历

**企业级 LLM 网关与长时记忆** | 同司 AI 基建 · 主导 2026.07-至今

**项目描述**:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

**主要挑战**:1. 端到端 30.1s、瓶颈无法定位:请求路径上同步 IO 阻塞异步事件循环,分段计时前无法区分是网络、写库还是第三方 2. 多厂商 API 各自为政:换厂商要改代码;一家故障断整条链路,换家还易踩同账号互切 3. 长时记忆向量单臂召回不足(P@1 0.853):重排该不该上、评测集是否可信,都缺量化依据

**核心优化与实现**:

- 性能:分段计时逐段排除,定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞;全异步化 + 连接池 + 用量写库转有界队列后台落库,端到端降至 **3.6s**
- 路由:抽象语义档位路由(轻 / 重模型),按请求复杂度自动选型,单会话成本 **-60%**
- 容灾:链式换家(防同账号互切)+ 线程本地连接与代次失效重建 + 5xx 发布闸 + 滚动替换,换厂商零代码改动
- 记忆:事件溯源(纯追加 SSOT + 投影),任何时点可重建;词法 / 向量双臂 RRF 融合,P@1 提升至 **0.907**
- 重排:cross-encoder 同口径 A/B 实测为负贡献(R@4 0.797 → 0.707),关停不引入负资产
- 评测治理:量化出评测工具自身 16.3% 翻面噪声,设定评测可信度门槛,不用不可信尺子做决策

**项目成果**:1. 端到端 30.1s → 3.6s;单会话成本 -60% 2. 记忆 P@1 0.853 → 0.907 3. 5 厂商 12 模型 9 客户端稳定运行 51 天

**技术栈**:Python asyncio、SSE 流式转发、ClickHouse、Redis、Prometheus 观测

**假发 AI 试戴(在线作品)** | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

**项目描述**:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

**主要挑战**:1. 人脸漂移:模型整图重画,脸必漂移,提示词约束不可靠 2. 旧发残留:长发改短发,旧发残留晕影 3. 速度与成本:后处理 85s 拖慢出图,公网并发下成本不可控

**核心优化与实现**:

- 对齐:补边 3:4 生成后逐像素裁回,与原图严格对位
- 合成:蒙版取原图旧发 ∪ 新发 alpha 并集,ViTMatte 发丝级合成,脸保持原图像素
- 质检:像素级核对 —— 脸区像素差 P99 **5~8**(对照 33)、身份 cos **0.958~0.975**(对照 0.918)
- 提速:分割 512→256、matting 512→384(逐区对照无差),后处理 85s → **14.7s**
- 成本与合规:并发闸 6 控成本;AI 生成标识(显式角标 + EXIF/COM 隐式)

**项目成果**:1. 脸区像素差 P99 5~8(对照 33),脸即原照片像素 2. 后处理 85s → 14.7s,公网端到端 48s 3. 已上线运营(独立域名 + LE 证书)

**技术栈**:Python、ARK 图像生成、ONNX 分割与 ViTMatte、FastAPI、Nginx + LE 证书

**Agent 工具调用微调与能力边界评测** | 独立作品 · 独立完成 2026

**项目描述**:Agent 工具调用微调实践:验证 Qwen3-0.6B 能否承接工具调用,给出能力边界

**主要挑战**:1. 小模型能不能接住工具调用:直接影响选型,缺答案 2. 单卡显存不足:全参微调跑不动 3. 评测:格式、选择、答案混成一个分,看不出边界

**核心优化与实现**:

- 数据:教师模型多轮 ReAct 合成 1140 条轨迹,6 条规则校验
- 训练:Qwen3-0.6B LoRA(r=16、α=32、lr 2e-5)
- 对照:2207 条全参 + DeepSpeed ZeRO-2 双卡,merge_and_unload 合回基座(推理零开销)
- 评测:格式 / 工具选择 / 答案三维度分离计分,避免总分掩盖边界

**项目成果**:1. 格式 **4/20** → **20/20** 全学会 2. 工具选择 **0/10** → **2/10**、答案 **0/10** → **2/10** 学不动 → 承接工具调用需 7B+ 或规则兜底

**技术栈**:Qwen3-0.6B、LoRA、DeepSpeed ZeRO-2、Transformers、Accelerate

**多模态 RAG 工程(图片语境化 + 在线自评)** | 独立作品 · 独立完成 2025.12-2026.06

**项目描述**:多模态 RAG 工程(个人作品):PDF 图文统一检索 + LangGraph 工作流 + RAGAS 在线自评

**主要挑战**:1. PDF 图片检索缺失:图与文本不在同一语义空间 2. 召回质量:单一向量召回不足 3. 答案质量无守门:RAG 答错没人拦

**核心优化与实现**:

- 解析:dots-OCR 版面解析(bbox、11 类元素)+ 两级切分
- 语境化:qwen3-vl 生成图片描述后向量化,图文共用稠密空间
- 检索:Milvus 单集合 dense + 服务端 BM25 双路融合,纯文本查询可召回图片
- 守门:RAGAS 自评接入 LangGraph 10 节点流程,检索侧不达标丢弃上下文,生成侧低于 0.7 触发人工审批,拒绝则联网兜底
- 工程:低分换信息源而非重新生成;RPM 限速 + 429 退避保障外部配额

**项目成果**:1. 纯文本查询可召回图片,省去自建 BM25 索引与一致性维护 2. 核心自研约 **2.8k** 行,10 节点工作流在线运行

**技术栈**:dots-OCR、qwen3-vl、Milvus(dense + 服务端 BM25)、LangGraph、RAGAS

**DeepResearch 深度研究编排引擎** | 独立作品 · 独立完成 2025.12-2026.06

**项目描述**:DeepResearch 深度研究编排引擎(个人作品):多 worker 并行 OODA 编排 + 终止控制 + 结构化输出降级

**主要挑战**:1. 无限迭代:深度研究容易失控,成本不可估 2. 单点失败:LLM 出 JSON 有失败率,失败不该整轮崩

**核心优化与实现**:

- 编排:任务分解后并行 OODA worker(上限 6、典型 3,查询预算按复杂度 3/5/8)
- 终止:三保险(迭代上下限、质量门 80、收益递减),最坏成本按迭代 × worker × 预算封顶

- 降级:结构化输出两级降级,失败返回低置信度骨架并将失败写入 limitations
- 服务化:FastAPI 202 + SSE 增量输出,拒删运行中任务

**项目成果**:1. 最坏成本可估;并行上限 6 worker(典型 3) 2. 单 worker 失败不拖垮整轮,失败对下游可见

**技术栈**:Python、FastAPI、SSE、并行 worker、结构化输出

**金融智能问答 Agent 平台** | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

**项目描述**:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

**主要挑战**:1. 规则基线误路由率偏高:错误路由导致答非所问与工具误调 2. 高风险操作无闸:AI 直连业务工具存在越权风险 3. 幻觉与越权话术:同一知识库对内 / 对外口径不同,直接暴露有合规风险 4. 效果验证无标准:工具调用链路的正确性缺评法

**核心优化与实现**:

- 编排:plan-execute 执行链,先规划再执行,收敛误路由
- 权限:**4 条权限闸**(scope 隔离、认证、用户、高风险显式放行),高风险操作必须人工放行
- 兜底:澄清 3 次自动转人工,把不确定性挡在人工兜底前
- 守门:**13 条**系统提示词约束(业务 8、知识 5)防幻觉与越权话术
- 可见性:内部、外部、用户三级可见性,审计脱敏在出口统一处理
- 评测:**45 条**离线评测集(澄清拦截、高风险转人工、多工具组合)+ 54 项自动化回归

**项目成果**:1. 双入口上线运行,高风险操作全走显式放行 2. 45 条评测集 + 54 项回归全绿

**技术栈**:Python、plan-execute 编排、LLM 工具调用、三级可见性、pytest 回归

## 工作经历

**重庆智识维度** | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

**同司 AI 基建** | 主导 2026.07-至今

- LLM 网关与长时记忆系统

**自主创业** | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

**小象优品** | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

**豌豆思维** | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

**上海盛大汽车** | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

**上海广升 • 上海致宇** | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

## 教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)