张建乐

大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 ｜ **近 3 年** AI 应用落地 ｜ **三次** 0-1 生产系统 ｜ **6.6s → 264ms** 稳定性治理

从提示词到上线全链路:Agent 编排、RAG 召回与评测、多模态生成与质量量化;做到公网可用与合规标识

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由 / 工具编排 / 幻觉守门 → **2026.07** AI 基建层:LLM 网关 / 长时记忆 / 多租户 → **2026.10** 多模态产品层:生成质量可量化 / 合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位 / 成本 / 发布闸)、长时记忆(事件溯源 + RRF)、多租户配额 / 密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回 / 重排 / 评测)、三层幻觉守门
- **多模态应用**:图像编辑生成 + 分割 / 发丝级 matting 后处理、质量可量化评测(像素差 / 身份相似度 / 色差)、成本闸与合规标识

项目经历

企业级 LLM 网关与长时记忆 ｜ 同司 AI 基建 · 主导 2026.07-至今

多厂商网关(换厂商不改代码)+ 长时记忆(事件溯源 + 双臂召回)

- **网关 • 问题**:端到端 30s:请求路径三处同步阻塞(CK 建连 + DDL 约 120ms)卡在异步事件循环;换厂商要改代码,一家挂断链
- **网关 • 行动**:分段计时定位 → 全异步化 + 连接池 + 有界队列;档位路由 + 链式换家 + 滚动替换(5xx 闸)
- **网关 • 结果**:**30.1s → 3.6s**;单会话成本 **-60%**;换厂商不改代码;51 天 5 厂商 / 12 模型 / 9 客户端稳定
- **记忆 • 问题**:向量单臂召回不足;重排该不该上没依据
- **记忆 • 行动**:事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF;重排同口径 A/B 实测,负贡献即关停
- **记忆 • 结果**:P@1 **0.853 → 0.907**;量化评测工具自身 16.3% 翻面噪声,不引负资产

假发 AI 试戴(在线作品) ｜ 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

不换脸管线 —— 只换发型,脸 / 身体 / 背景保持原照片像素

- **对齐 • 问题**:模型整图重画脸会漂移(提示词约束不可靠);长 → 短换发旧发残留
- **对齐 • 行动**:补边 3:4 → ARK 生成 → 逐像素裁回 → 蒙版并集 + ViTMatte 发丝级 → composite 合成
- **对齐 • 结果**:脸区像素差 P99 **5~8**(对照 33)、身份 cos **0.958~0.975** —— 脸就是原照片像素
- **性能 • 问题**:后处理 85s 拖慢出图;公网并发要控成本
- **性能 • 行动**:分割 512→256、matting 512→384(逐区对照无差);并发闸 6 + AI 标识(显式 + 隐式)
- **性能 • 结果**:后处理 **85s → 14.7s**;公网端到端 **48.0s**,已上线

Agent 工具调用微调 —— 能力边界量化 ｜ 独立作品 · 独立完成 2026

小模型 + 轨迹 SFT 能学会什么、学不会什么 —— 三维度分离评测给出量化答案

- **训练 • 问题**:Agent 工具调用依赖大模型 API,小模型 + 轨迹 SFT 能接哪一层缺答案
- **训练 • 行动**:ReAct 合成 1140 条轨迹(6 条规则校验)→ Qwen3-0.6B LoRA;2207 条全参 + DeepSpeed ZeRO-2 双卡
- **训练 • 结果**:全参双卡跑通、checkpoint 在案;merge_and_unload 合回基座,推理零开销
- **边界 • 问题**:「学没学会」需要不混成一个分的评法
- **边界 • 行动**:三维度分离评测 —— 格式 / 工具选择 / 答案各自算分

- **边界 • 结果**:格式 **4/20** → **20/20** 全学会;工具选择 **0/10** → **2/10**、答案 **0/10** → **2/10** 学不动 → 0.6B 会格式、学不动选择(需 7B+ 或规则兜底)

多模态 RAG 工程(图片语境化 + 在线自评) | 独立作品 · 独立完成 2025.12-2026.06

dots-OCR 版面解析 → 图片语境化入库 → Milvus 双路检索 → LangGraph 10 节点 + RAGAS 在线自评

- **入库 • 问题**:PDF 图片检索不到(图与文本不在同一语义空间)
- **入库 • 行动**:dots-OCR 版面解析(bbox + 11 类)→ 两级切分 → qwen3-vl 语境化 → Milvus + 服务端 BM25
- **入库 • 结果**:核心自研约 2.8k 行;纯文本查询可召回图片,省掉自建 BM25 索引
- **自评 • 问题**:RAG 答错无人拦
- **自评 • 行动**:LangGraph 10 节点;RAGAS 在线自评 —— <0.7 触发人工审批,拒则联网兜底
- **自评 • 结果**:低分不重生成而换信息源(方向错时重生成只烧 token)

DeepResearch 深度研究编排引擎 | 独立作品 · 独立完成 2025.12-2026.06

OODA 并行编排 + 终止三保险:把深度研究的无限迭代压成可估成本

- **编排 • 问题**:深度研究易失控:无限迭代、成本不可估
- **编排 • 行动**:任务分解 → 并行 OODA worker(≤6 / 典型 3,预算 3/5/8)+ 终止三保险(上下限 + 质量门 + 收益递减)
- **编排 • 结果**:最坏成本可估(迭代 × worker × 预算三重上限)
- **降级 • 问题**:LLM 出 JSON 有失败率,失败不该整轮崩
- **降级 • 行动**:结构化输出两级降级,失败返回低置信度骨架 + limitations 透出
- **降级 • 结果**:单 worker 失败不拖垮整轮;服务化契约完整(202 / SSE / 拒删运行中)

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路(撞库 → 前筛 → 路由 → 授信 / 放款 → 对账)

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间:自研量化 / AI 员工 / 多模态 RAG / DeepResearch 系统

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产 / 资金端重构、锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)