张建乐

大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

LLM 应用从原型做到上线:Agent 编排、多模态生成、小模型微调;有公网在线的多模态产品

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting、质量量化评测(像素差、身份相似度)、成本闸与合规标识

项目经历

企业级 LLM 网关与长时记忆 | 重庆智识维度 · 主导 2026.07-至今

项目描述:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

主要挑战:1. 端到端 30.1s、瓶颈无法定位:CK 建连、DDL 元数据查询(约 120ms)等多处同步 IO 阻塞在异步事件循环里,无法区分是网络、写库还是第三方 API 慢 2. 多厂商 API 各自为政:协议、错误码、限流策略不同,换厂商要改代码;一家故障断整条链路,切备用账号还有同账号互切的坑 3. 长时记忆召回不足:向量单臂 P@1 仅 0.853,长尾命中差;重排收益与评测集可信度缺量化依据

核心优化与实现:

- **1. 请求链路与性能**
- 分段计时:请求路径逐段计时,定位到 CK 建连与 DDL(约 120ms)三处同步阻塞
- 全异步化 + 连接池:同步 IO 全改异步(asyncio)、连接复用;用量写库转有界队列后台落库,不阻塞请求路径,端到端降至 **3.6s**
- **2. 多厂商适配与容灾**
- 档位路由:抽象轻 / 重语义档位,按请求复杂度自动选模型,单会话成本 **-60%**
- 链式换家:故障时链式切换备用厂商(防同账号互切),线程本地连接 + 代次失效重建,换厂商零代码改动
- 发布闸:滚动替换 + 5xx 比例闸,异常版本在发布过程自动拦截
- **3. 长时记忆存储与召回**
- 事件溯源:纯追加 SSOT + 投影,任何时点可重建记忆状态
- 双臂召回:词法 + 向量 RRF 融合;修剪序(重排只过滤不接管排序)后端到端 P@1 0.853 → **0.907**(n=75 同口径 A/B)
- 重排复验:cross-encoder n=300 复验负贡献(R@4 0.797 → 0.707),已下架
- 评测量尺自审:旧校验集别名泄漏(目标 100% 带手写别名)+ CI 重叠 → 作废该批数字,重建去泄漏 held-out 评测(n=728):融合增益 R@10 0.870 → **0.911** 仍成立
- 评测治理:量化出评测工具自身 16.3% 翻面噪声,设定评测可信度门槛
- 推理加速:embedding 与精排服务 OpenVINO 部署,精排 715ms → 45ms(16 倍);踩过 FP16 默认损精度(向量 cos<1),显式切 f32 保真

项目成果:1. 性能与成本:端到端 30.1s → 3.6s,单会话成本 -60%;支撑 9 个客户端、5 厂商 12 模型稳定运行 51 天 2. 记忆质量:端到端 P@1 0.853 → 0.907;重排负贡献 n=300 复验否决下架;去泄漏评测(n=728)复核双臂增益 R@10 0.870 → 0.911 3. 评测可信:16.3% 翻面噪声被量化并设为门槛,决策有可信依据

技术栈:

- 服务:Python asyncio、SSE 流式转发、有界队列
- 存储与观测:ClickHouse、Redis、Prometheus;容灾:链式换家、代次失效重建、发布闸

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

项目描述:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

主要挑战:1. 人脸漂移:模型整图重画,脸必漂移;提示词约束不可靠,换发后脸不一致,效果不可信 2. 旧发残留:长发改短发时,生成图里的旧发在边缘残留晕影 3. 速度与成本:后处理 85s 拖慢出图;公网并发下 API 成本不可控 4. 合规:AI 生成内容需标识,人脸素材需单独同意

核心优化与实现:

- **1. 不换脸合成管线**
- 像素级对齐:补边 3:4 生成后逐像素裁回,与原图严格对位
- 蒙版合成:蒙版取原图旧发 ∪ 新发 alpha 并集,ViTMatte 发丝级 matting,脸、身体、背景保持原照片像素
- 质检量化:脸区像素差 P99 **5~8**(仅提示词对照 33)、身份 cos **0.958~0.975**(对照 0.918),量化支撑换发不换脸
- **2. 性能与成本**
- 分辨率降档:分割 512→256、matting 512→384,3x 放大逐区对照确认视觉无差,后处理 85s → **14.7s**
- 并发闸:同时最多 6 个任务,API 成本可控
- **3. 合规标识**
- AI 生成标识:显式角标 + EXIF/COM 隐式双写;人脸素材单独同意弹层

项目成果:1. 脸区像素差 P99 5~8(对照 33):脸即原照片像素,换发不换脸 2. 后处理 85s → 14.7s,公网端到端 48s 3. 已上线运营(独立域名 + LE 证书),合规标识随图输出

技术栈:

- 生成:ARK 图像生成、补边对齐、蒙版合成;后处理:ONNX 分割、ViTMatte 发丝级 matting
- 服务:FastAPI、并发闸 6、Nginx + LE 证书

Agent 工具调用微调与能力边界评测 | 独立作品 · 独立完成 2026

项目描述:Agent 工具调用微调实践:验证 Qwen3-0.6B 能否承接工具调用,给出能力边界

主要挑战:1. 小模型能不能接住工具调用:直接影响选型(小模型省成本),但缺可验证答案 2. 单卡显存不足:全参微调跑不动,需要分布式方案 3. 评测:格式、工具选择、答案混成一个分,看不出到底哪一层没学会

核心优化与实现:

- **1. 数据与训练**
- 轨迹合成:教师模型多轮 ReAct 合成 1140 条工具调用轨迹,6 条规则校验数据质量
- LoRA 微调:Qwen3-0.6B,r=16、α=32、lr 2e-5,单卡可跑
- 全参对照:2207 条全参微调,DeepSpeed ZeRO-2 切优化器状态与梯度,双卡跑通;merge_and_unload 合回基座,推理零开销
- **2. 三维度评测**
- 三维度分离:格式 / 工具选择 / 答案分别计分,分项暴露能力边界

项目成果:1. 格式 **4/20** → **20/20**:格式层完全学会 2. 工具选择 **0/10** → **2/10**、答案 **0/10** → **2/10**:学不动 → 承接工具调用需 7B+ 或规则兜底 3. 结论量化,直接支撑选型决策

技术栈:

- 模型:Qwen3-0.6B、LoRA(r=16、α=32);训练:DeepSpeed ZeRO-2、Transformers、Accelerate
- 评测:三维度分离评测集

金融智能问答 Agent 平台 | 小象优品 · 核心开发(10-20 人) 2024.06-2025.11

项目描述:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

主要挑战:1. 规则基线误路由:问题意图靠规则匹配,答非所问与工具误调,影响坐席效率 2. 高风险操作无闸:AI 直连业务工具存在越权风险,改单、退费类操作需要人工确认 3. 幻觉与越权话术:知识库对内 / 对外口径不同,直接暴露给用户有合规风险 4. 效果验证无标准:工具调用正确性缺评法,改一次提示词不知好坏

核心优化与实现:

- **1. 编排与权限**
- plan-execute 执行链:先规划再执行,复杂问题拆解后逐步执行,收敛误路由
- **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行):高风险操作必须人工放行
- 澄清兜底:意图不明确时最多澄清 3 次,超过自动转人工
- **2. 幻觉与合规守门**
- **13 条**系统提示词约束(业务 8、知识 5):约束回答范围与话术,防幻觉与越权承诺
- 三级可见性:内部、外部、用户三级内容隔离,审计脱敏在出口统一处理
- **3. 效果验证**
- **45 条**离线评测集:覆盖澄清拦截、高风险转人工、多工具组合三类场景
- 54 项自动化回归:提示词与编排改动必须过回归,防止改一处坏一处

项目成果:1. 双入口上线运行,高风险操作全走显式放行闸 2. 45 条评测集 + 54 项回归通过,提示词迭代有依据

技术栈:

- 应用:Python、plan-execute 编排、LLM 工具调用
- 治理与验证:4 条权限闸、13 条提示词约束、三级可见性、pytest 54 项回归

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路(撞库、前筛、路由、授信放款、对账);兼公司 AI 基建:LLM 网关与长时记忆

自主创业 | 独立开发 2025.12-2026.06

- 自研 AI 员工(智能体)系统,并以该模式承接项目交付、部署生产、产生实际收入;同期在读 AI 方向硕士;自研量化系统、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建 10-20 人金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理;独立承接两个项目

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台(带 10-20 人团队):订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 • 上海广升/致宇 | Java 开发 → 高级开发 2016.07-2020.05

- 金融租赁平台与呼叫中心链路(双呼、幂等去重);系统工具后端与银行方向 Java 开发

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)

- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)