张建乐

大模型应用开发 • 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

LLM 应用从原型做到上线:RAG、多模态生成、Agent 编排、小模型微调;有公网在线的多模态产品

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识

项目经历

企业级 LLM 网关与长时记忆 | 同司 AI 基建 · 主导 2026.07-至今

项目描述:公司级 AI 基建,统一接入 5 家大模型厂商(12 模型),为 9 个客户端提供网关、长时记忆与成本计量,支撑全公司 AI 研发流水线

主要挑战:1. 端到端 30.1s、瓶颈无法定位:请求路径上 CK 建连、DDL 元数据查询(约 120ms)等多处同步 IO 阻塞在异步事件循环里,分段计时前无法区分是网络、写库还是第三方 API 慢 2. 多厂商 API 各自为政:各家协议、错误码、限流策略不同,换厂商要改代码;一家故障断整条链路,简单切备用账号还会踩同账号互切的坑 3. 长时记忆召回不足:向量单臂召回 P@1 仅 0.853,长尾问题命中差;重排该不该上、评测集本身是否可信,都缺量化依据

核心优化与实现:

- **性能治理**
- 分段计时定位:请求路径埋点逐段计时,定位到 CK 建连与 DDL(约 120ms)等三处同步阻塞,而非凭经验猜测
- 全异步化 + 连接池:同步 IO 全改异步、连接复用;用量写库转有界队列后台落库,不阻塞请求路径,端到端降至 **3.6s**
- **多厂商接入与容灾**
- 档位路由:抽象轻 / 重语义档位,按请求复杂度自动选模型,单会话成本 **-60%**
- 链式换家:故障时链式切换备用厂商(防同账号互切),线程本地连接 + 代次失效重建,换厂商零代码改动
- 发布闸:滚动替换 + 5xx 比例闸,异常版本在发布过程自动拦截
- **长时记忆**
- 事件溯源:纯追加 SSOT + 投影,任何时点可重建记忆状态
- 双臂召回:词法 + 向量 RRF 融合,P@1 0.853 → **0.907**
- 重排实测:cross-encoder 同口径 A/B 为负贡献(R@4 0.797 → 0.707),关停不引入负资产
- 评测治理:量化出评测工具自身 16.3% 翻面噪声,设定评测可信度门槛

项目成果:1. 性能与成本:端到端 30.1s → 3.6s,单会话成本 -60%;支撑 9 个客户端、5 厂商 12 模型稳定运行 51 天 2. 记忆质量:P@1 0.853 → 0.907;重排负贡献被实测否决,未引入负资产 3. 评测可信:评测工具 16.3% 翻面噪声被量化并设为门槛,不用不可信尺子做技术决策

技术栈:

- 服务:Python asyncio、SSE 流式转发、有界队列
- 存储与观测:ClickHouse、Redis、Prometheus
- 容灾:链式换家、代次失效重建、滚动替换 + 5xx 发布闸

假发 AI 试戴(在线作品) | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

项目描述:假发试戴 H5 在线产品(公网运营):上传照片换发型,要求脸、身体、背景保持原照片像素;含成本闸与 AI 生成标识合规

主要挑战:1. 人脸漂移:模型整图重画,脸必漂移;提示词约束不可靠,换一次发型脸变一次,用户一眼看出假 2. 旧发残留:长发改短发时,生成图里的旧发在边缘残留晕影 3. 速度与成本:后处理 85s 拖慢出图体验;公网并发下 API 成本不可控 4. 合规:AI 生成内容需按监管要求标识,人脸素材涉及单独同意

核心优化与实现:

- **不换脸管线**
- 像素级对齐:补边 3:4 生成后逐像素裁回,与原图严格对位,不做整图重绘
- 蒙版合成:蒙版取原图旧发 ∪ 新发 alpha 并集,ViTMatte 发丝级 matting,脸、身体、背景保持原照片像素
- 质检量化:脸区像素差 P99 **5~8**(仅提示词对照 33)、身份 cos **0.958~0.975**(对照 0.918),「换发不换脸」可证明
- **性能与成本**
- 分辨率降档:分割 512→256、matting 512→384,3x 放大逐区对照确认视觉无差,后处理 85s → **14.7s**
- 并发闸:同时最多 6 个任务,API 成本可控
- **合规**
- AI 生成标识:显式角标 + EXIF/COM 隐式双写;人脸素材单独同意弹层

项目成果:1. 脸区像素差 P99 5~8(对照 33):脸即原照片像素,换发不换脸 2. 后处理 85s → 14.7s,公网端到端 48s 3. 已上线运营(独立域名 + LE 证书),合规标识随图输出

技术栈:

- 生成:ARK 图像生成、补边对齐、蒙版合成
- 后处理:ONNX 分割、ViTMatte 发丝级 matting
- 服务:FastAPI、并发闸 6、Nginx + LE 证书

Agent 工具调用微调与能力边界评测 | 独立作品 · 独立完成 2026

项目描述:Agent 工具调用微调实践:验证 Qwen3-0.6B 能否承接工具调用,给出能力边界

主要挑战:1. 小模型能不能接住工具调用:直接影响选型(小模型省成本),但缺可验证答案 2. 单卡显存不足:全参微调跑不动,需要分布式方案 3. 评测:格式、工具选择、答案混成一个分,看不出到底哪一层没学会

核心优化与实现:

- **数据与训练**
- 轨迹合成:教师模型多轮 ReAct 合成 1140 条工具调用轨迹,6 条规则校验数据质量
- LoRA 微调:Qwen3-0.6B,r=16、α=32、lr 2e-5,单卡可跑
- 全参对照:2207 条全参微调,DeepSpeed ZeRO-2 切优化器状态与梯度,双卡跑通;merge_and_unload 合回基座,推理零开销
- **评测**
- 三维度分离:格式 / 工具选择 / 答案分别计分,避免总分掩盖边界

项目成果:1. 格式 **4/20** → **20/20**:格式层完全学会 2. 工具选择 **0/10** → **2/10**、答案 **0/10** → **2/10**:学不动 → 承接工具调用需 7B+ 或规则兜底 3. 结论量化,直接支撑选型决策

技术栈:

- 模型:Qwen3-0.6B、LoRA(r=16、α=32)
- 训练:DeepSpeed ZeRO-2、Transformers、Accelerate
- 评测:三维度分离评测集

多模态 RAG 工程(图片语境化 + 在线自评) | 独立作品 · 独立完成 2025.12-2026.06

项目描述:多模态 RAG 工程(个人作品):PDF 图文统一检索 + LangGraph 工作流 + RAGAS 在线自评

主要挑战:1. PDF 图片检索缺失:图与文本不在同一语义空间,纯文本查询召不回图片 2. 召回质量:单一向量召回不足,长尾与专业词命中差 3. 答案质量无守门:RAG 答错没人拦,错了也不知道

核心优化与实现:

- **图文统一入库**
- 版面解析:dots-OCR 解析 bbox 与 11 类元素,两级切分保留文档结构
- 图片语境化:qwen3-vl 生成图片描述后向量化,图文共用稠密空间
- **检索**
- 双路融合:Milvus 单集合 dense + 服务端 BM25,纯文本查询可召回图片,省去自建 BM25 索引与一致性维护
- **质量守门**
- RAGAS 自评入流程:接入 LangGraph 10 节点工作流,检索侧不达标丢弃上下文
- 生成侧守门:低于 0.7 触发人工审批,拒绝则联网兜底;低分换信息源而非重新生成(方向错误时重生成仅消耗 token)
- 配额保障:Embedding 侧 RPM 限速 + 429 退避

项目成果:1. 纯文本查询可召回图片,省去自建 BM25 索引与一致性维护 2. 核心自研约 **2.8k** 行,10 节点工作流在线运行

技术栈:

- 解析:dots-OCR、qwen3-vl 图片语境化
- 检索:Milvus(dense + 服务端 BM25)
- 编排与评估:LangGraph 10 节点、RAGAS 在线自评

DeepResearch 深度研究编排引擎 | 独立作品 · 独立完成 2025.12-2026.06

项目描述:DeepResearch 深度研究编排引擎(个人作品):多 worker 并行 OODA 编排 + 终止控制 + 结构化输出降级

主要挑战:1. 无限迭代:深度研究容易失控,成本不可估,没人知道会跑多久 2. 单点失败:LLM 出 JSON 有失败率,一个 worker 失败不该整轮崩

核心优化与实现:

- **并行编排**
- OODA worker:任务分解后并行执行,上限 6、典型 3,查询预算按复杂度 3/5/8
- 终止三保险:迭代上下限、质量门 80、收益递减,最坏成本按迭代 × worker × 预算封顶
- **降级与服务化**
- 结构化输出两级降级:失败返回低置信度骨架,并将失败写入 limitations,对下游可见
- 服务化:FastAPI 202 + SSE 增量输出,拒删运行中任务

项目成果:1. 最坏成本可估(迭代 × worker × 预算三重上限) 2. 单 worker 失败不拖垮整轮,失败对下游可见

技术栈:

- 编排:OODA 并行 worker、终止三保险
- 服务:FastAPI 202 + SSE 增量输出
- 稳健性:结构化输出两级降级

金融智能问答 Agent 平台 | 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

项目描述:消费金融智能问答 Agent,内部(坐席、风控)与外部(用户)双入口,承载业务问答、工具调用与高风险操作分流

主要挑战:1. 规则基线误路由率偏高:问题意图靠规则匹配,错误路由导致答非所问与工具误调,影响坐席效率 2. 高风险操作无闸:AI 直连业务工具存在越权风险,改单、退费类操作需要人工确认 3. 幻觉与越权话术:同一知识库对内 / 对外口径不同,直接暴露给用户有合规风险 4. 效果验证无标准:工具调用链路的正确性缺评法,改一次提示词不知道是好是坏

核心优化与实现:

- **编排与权限**
- plan-execute 执行链:先规划再执行,复杂问题拆解后逐步执行,收敛误路由
- **4 条权限闸**(scope 隔离、认证、用户、高风险显式放行):高风险操作必须人工放行,AI 不自行执行
- 澄清兜底:意图不明确时最多澄清 3 次,超过自动转人工,把不确定性挡在人工兜底前
- **幻觉与合规守门**
- **13 条**系统提示词约束(业务 8、知识 5):约束回答范围与话术,防幻觉与越权承诺
- 三级可见性:内部、外部、用户三级内容隔离,审计脱敏在出口统一处理
- **效果验证**
- **45 条**离线评测集:覆盖澄清拦截、高风险转人工、多工具组合三类场景
- 54 项自动化回归:提示词与编排改动必须过回归,防止改一处坏一处

项目成果:1. 双入口上线运行,高风险操作全走显式放行闸 2. 45 条评测集 + 54 项回归全绿,提示词迭代有依据

技术栈:

- 应用:Python、plan-execute 编排、LLM 工具调用
- 治理:4 条权限闸、13 条提示词约束、三级可见性
- 验证:45 条评测集、pytest 54 项回归

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)