张建乐

大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

10 年 后端与架构 ｜ **近 3 年** AI 应用落地 ｜ **三次** 0-1 生产系统 ｜ **6.6s → 264ms** 稳定性治理

从提示词到上线全链路:Agent 编排、RAG 召回与评测、多模态生成与质量量化;做到公网可用与合规标识

AI 轨迹(近 3 年)

2024.06 Agent 应用层:意图路由 / 工具编排 / 幻觉守门 → **2026.07** AI 基建层:LLM 网关 / 长时记忆 / 多租户 → **2026.10** 多模态产品层:生成质量可量化 / 合规上线

核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象 / 成本计量 / 滚动发布闸)、长时记忆(事件溯源 + 双臂召回 RRF)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回 / 重排 / 评测)、三层幻觉守门
- **多模态应用**:图像编辑生成 + 分割 / 发丝级 matting 后处理、质量可量化评测(像素差 / 身份相似度 / 色差)、成本闸与合规标识

项目经历

假发 AI 试戴(在线作品) ｜ 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

不换脸管线 —— 只换发型,脸 / 身体 / 背景保持原照片像素

- **问题**:模型整图重画,脸会漂移(提示词级约束不可靠);长 → 短换发旧发残留;后处理 85s 拖慢出图
- **行动**:补边 3:4 → ARK 生成 → 裁回逐像素对位 → 蒙版取「原图旧发羽化区 ∪ 生成图新发 alpha」并集 → ViTMatte 发丝级 alpha → Image.composite 合成;分割 512→256、matting 512→384(逐区对照视觉无差)
- **结果**:脸区像素差降到 JPEG 噪声级(**P99 5~8**,对照仅提示词 33)、身份 cos **0.958~0.975**;后处理 **85s → 14.7s**,公网端到端 **48.0s**;并发闸 6 控成本 + AI 生成标识(显式角标 + EXIF/COM 隐式)

企业级 LLM 网关与长时记忆 ｜ 同司 AI 基建 · 主导 2026.07-至今

多厂商网关(换厂商不改代码)+ 长时记忆(事件溯源 + 双臂召回)

- **问题**:网关端到端 30s —— 请求路径三处同步阻塞(CK 建连 + DDL 约 120ms)卡在异步事件循环,端到端测不出瓶颈;长时记忆单臂向量召回不足;换厂商要改代码
- **行动**:分段计时定位阻塞点 → 全异步化 + 连接池 + 用量写库转有界队列(2000)后台线程落库;事件溯源(纯追加 SSOT + 投影)+ 词法 / 向量双臂 RRF 融合 + 强命中保护;语义档位路由(轻 / 重模型)+ 多租户日配额与 key 隔离 + 双实例滚动替换(5xx 发布闸,失败回退旧 tag);评测先行 —— 重排上线前实测负贡献即关停
- **结果**:端到端 **30.1s → 3.6s**;P@1 **0.853 → 0.907**(n=75 同口径 A/B);重排 **R@4 0.797 → 0.707** 被实测否决(并量化评测工具自身 16.3% 翻面噪声);单会话成本 **-60%**;5 厂商 / 12 模型 / 9 客户端 · 51 天稳定

金融智能问答 Agent 平台 ｜ 小象优品 · 核心开发(3-5 人) 2024.06-2025.11

plan-execute 编排 + 权限闸 + 三层幻觉守门,内部与外部双入口

- **问题**:规则基线误路由偏高;内部 / 外部双入口,高风险操作需安全合规
- **行动**:plan-execute 执行链 + **4 条权限闸**(scope 隔离 / 认证 / 用户 / 高风险显式放行)+ 连续澄清 3 次自动转人工;两套系统提示词 **13 条**强制约束(业务 8 + 知识 5)+ 内 / 外 / 用户三级可见性 + 审计脱敏
- **结果**:**45 条离线评测集**覆盖澄清拦截 / 高风险转人工 / 多工具组合;54 项回归全绿;双入口已上线运行

Agent 工具调用微调 —— 能力边界量化 | 独立作品 · 独立完成 2026

小模型 + 轨迹 SFT 能学会什么、学不会什么 —— 三维度分离评测给出量化答案

- **问题**:Agent 工具调用依赖大模型 API,「小模型 + 轨迹 SFT 能承接哪一层」缺量化答案 → 摸清边界给选型依据
- **行动**:教师模型多轮 ReAct 合成 1140 条工具调用轨迹(6 条规则校验)→ Qwen3-0.6B LoRA(r=16 / α=32)→ 三维度分离评测(格式 / 选择 / 答案各自算分);另 2207 条多轮全参对照 + DeepSpeed ZeRO-2 双卡分布式
- **结果**:格式 **4/20 → 20/20** 全学会;工具选择 **0/10 → 2/10**、答案 **0/10 → 2/10** 学不动 → 量化出「0.6B 学得会格式、学不动工具选择」的边界 → 工具选择需 7B+ 或规则兜底

多模态 RAG 工程(图片语境化 + 在线自评) | 独立作品 · 独立完成 2025.12-2026.06

dots-OCR 版面解析 → 图片语境化入库 → Milvus 双路检索 → LangGraph 10 节点 + RAGAS 在线自评

- **问题**:PDF 图片检索不到(图与文本不在同一语义空间);RAG 答错无人拦
- **行动**:dots-OCR(vLLM)版面解析(bbox + 11 类元素)→ 两级切分 → qwen3-vl 图片语境化(图文共用稠密空间)→ Milvus dense + 服务端 BM25 融合 → LangGraph 10 节点;RAGAS 在线自评:<0.7 触发人工审批,拒则联网兜底
- **结果**:核心自研约 2.8k 行;纯文本查询可召回图片;限流 + 429 退避把批量入库变节奏控制

DeepResearch 深度研究编排引擎 | 独立作品 · 独立完成 2025.12-2026.06

OODA 并行编排 + 终止三保险:把深度研究的无限迭代压成可估成本

- **问题**:深度研究易失控:无限迭代、成本不可估;LLM 出 JSON 有失败率,失败不该整轮崩
- **行动**:任务分解(depth / breadth / simple)→ 并行 OODA worker(上限 6 / 典型 3,查询预算按复杂度 3/5/8)+ 终止三保险(迭代上下限 + 质量门 80 + 收益递减判停);结构化输出失败降级低置信度骨架;FastAPI 202 + SSE 增量
- **结果**:4.1k 行 / 9 模块;最坏成本可估(迭代 × worker × 预算三重上限);服务化契约完整(202 / SSE / 拒删运行中)

工作经历

重庆智识维度 | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路(撞库 → 前筛 → 路由 → 授信 / 放款 → 对账)

同司 AI 基建 | 主导 2026.07-至今

- LLM 网关与长时记忆系统

自主创业 | 独立开发 2025.12-2026.06

- 在读硕士期间:自研量化 / AI 员工 / 多模态 RAG / DeepResearch 系统

小象优品 | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产 / 资金端重构、锁治理

豌豆思维 | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

上海盛大汽车 | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

上海广升 • 上海致宇 | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)