# 张建乐

## 大模型应用开发 · 应用落地

电话 15221599617 · 邮箱 zhangjianle617@163.com · 在线简历 zzbjll.github.io/resume · 可随时到岗

**10 年** 后端与架构 | **近 3 年** AI 应用落地 | **三次** 0-1 生产系统 | **6.6s → 264ms** 稳定性治理

LLM 应用从原型做到上线:RAG、多模态生成、Agent 编排、小模型微调;有公网在线的多模态产品

## AI 轨迹(近 3 年)

**2024.06** Agent 应用层:意图路由、工具编排、幻觉守门 → **2026.07** AI 基建层:LLM 网关、长时记忆、多租户 → **2026.10** 多模态产品层:生成质量可量化、合规上线

## 核心能力

- **AI 平台架构**:多厂商 LLM 网关(档位抽象、成本计量、发布闸)、长时记忆(事件溯源、双臂召回)、多租户配额与密钥隔离、MCP
- **Agent 与 RAG**:Multi-Agent 编排、Tool Calling 与权限闸、RAG 全链路(混合召回、重排、评测)、三层幻觉守门
- **多模态应用**:图像生成编辑、分割与发丝级 matting 后处理、质量量化评测(像素差、身份相似度、色差)、成本闸与合规标识

## 项目经历

**企业级 LLM 网关与长时记忆** | 同司 AI 基建 · 主导 2026.07-至今

多厂商 LLM 网关与长时记忆(事件溯源、双臂召回)

- 网关端到端 30s、测不出瓶颈在哪:分段计时定位到 CK 建连与 DDL 约 120ms 等三处同步阻塞卡在异步循环,全异步化 + 连接池 + 用量有界队列,降到 **3.6s**
- 换厂商要改代码、一家挂了断整条链路:抽象成档位路由,加链式换家与 5xx 发布闸;现在换厂商不动代码,单会话成本 **-60%**,5 厂商 12 模型 9 客户端跑了 51 天
- 长时记忆只有向量单臂召回,P@1 0.853:改事件溯源(纯追加 SSOT + 投影)加词法与向量双臂 RRF 融合,提到 **0.907**;重排同口径 A/B 实测是负贡献,没上,还量化出评测工具自身 16.3% 翻面噪声

**假发 AI 试戴(在线作品)** | 独立作品 · 自有业务线 · 设计 + 开发 + 上线 独立完成 2026.10

只换发型不换脸:脸、身体、背景保持原照片像素

- 模型整图重画脸会漂移、提示词约束不住,长发改短发还有旧发残留:补边 3:4 生成后逐像素裁回,蒙版取原图旧发与新发 alpha 的并集,ViTMatte 发丝级合成,脸保持原图像素
- 效果按像素核对:脸区像素差 P99 **5~8**(对照组 33),身份 cos **0.958~0.975**
- 后处理 85s 拖慢出图:分割降到 512→256、matting 降到 512→384(逐区对照视觉无差),后处理 **14.7s**,公网端到端 **48s**
- 并发闸 6 控制成本,AI 生成标识按合规加(显式角标 + EXIF/COM 隐式),已上线

**Agent 工具调用微调与能力边界评测** | 独立作品 · 独立完成 2026

Qwen3-0.6B 工具调用微调,三维度评测量化能力边界

- 想摸清小模型能不能接住 Agent 工具调用:教师模型多轮 ReAct 合成 1140 条轨迹(6 条规则校验),Qwen3-0.6B 上 LoRA;另跑 2207 条全参对照,DeepSpeed ZeRO-2 双卡,merge_and_unload 合回基座
- 评测拆成格式、工具选择、答案三个维度分别算分:格式 **4/20 → 20/20** 全学会,工具选择 **0/10 → 2/10**、答案 **0/10 → 2/10** 学不动
- 结论:0.6B 学得会格式、学不动工具选择,要接工具调用得 7B+ 或规则兜底

**多模态 RAG 工程(图片语境化 + 在线自评)** | 独立作品 · 独立完成 2025.12-2026.06

多模态 RAG:图片语境化入库、Milvus 双路检索、RAGAS 在线自评

- PDF 里的图片检索不到,图和文本不在同一语义空间:用 dots-OCR 做版面解析(bbox、11 类元素)和两级切分,qwen3-vl 给图片生成语境化描述再向量化,图文共用稠密空间,Milvus 单集合 dense 加服务端 BM25 双路融合
- 核心自研约 **2.8k** 行,纯文本查询能召回图片,省掉自建 BM25 索引
- RAG 答错没人拦:把 RAGAS 自评接进 LangGraph 10 节点流程,检索侧不达标就丢弃上下文,生成侧低于 0.7 触发人工审批,拒了联网兜底,低分换信息源而不是重生成

**DeepResearch 深度研究编排引擎** | 独立作品 · 独立完成 2025.12-2026.06

OODA 并行编排加终止三保险,深度研究成本可控

- 深度研究容易无限迭代、成本不可估:任务分解后并行跑 OODA worker(上限 6、典型 3,查询预算按复杂度 3/5/8),终止用三保险:迭代上下限、质量门 80、收益递减,最坏成本按迭代 × worker × 预算封顶
- LLM 出 JSON 有失败率,失败不该整轮崩:结构化输出做两级降级,失败返回低置信度骨架并把失败写进 limitations,单 worker 失败不拖垮整轮
- 服务化按 FastAPI 202 + SSE 做增量,拒删运行中的任务

## 工作经历

**重庆智识维度** | 技术负责人 2026.06-至今

- 贷超导流双产品线全链路:撞库、前筛、路由、授信放款、对账

**同司 AI 基建** | 主导 2026.07-至今

- LLM 网关与长时记忆系统

**自主创业** | 独立开发 2025.12-2026.06

- 在读硕士期间自研:量化系统、AI 员工、多模态 RAG、DeepResearch

**小象优品** | Java 资深开发 2021.12-2025.11

- 0-1 组建金融技术团队;消费金融核心链路(2024.06 起兼 Agent 平台):资产端、资金端重构与锁治理

**豌豆思维** | Java 高级开发 2020.11-2021.11

- 运营中台:订单分表与 ES 检索链路、质检批处理链路

**上海盛大汽车** | Java 高级开发 2018.07-2020.05

- 金融租赁平台;呼叫中心与通知链路(双呼、幂等去重);存储过程 Java 化

**上海广升 • 上海致宇** | Java 开发 2016.07-2018.07

- 系统工具后端与银行方向 Java 开发(早期两段)

## 教育背景

- 史蒂文斯理工学院 · 计算机科学 硕士(在读,AI 方向,2025.09-2027.06)
- 徐州工程学院 · 计算机科学与技术 本科(统招全日制,2012.09-2016.06)
- 阿里云大模型 ACP(2026.04)· 上海市人工智能训练师三级(2025.09)